


REPORT DI ANALISI: REPUTAZIONE E PERFORMANCE DELL'HOTELLERIE EUROPEA (2015-2017)

Angela Isabella Cilenti



Introduzione e Obiettivi del Progetto

Il presente report analizza un dataset massivo proveniente da **Booking.com**, comprendente **515.000 recensioni** autentiche relative a **1.493 hotel di lusso** situati in sei delle principali capitali europee.

L'obiettivo dell'analisi è duplice:

- **Tecnico:** Costruire un'architettura dati solida che integri Python e SQL in una pipeline sincronizzata.
- **Analitico:** Estrarre insight strategici sulla qualità percepita, i comportamenti dei viaggiatori e le differenze regionali nel settore dell'ospitalità.

Metodologia: La Pipeline dei Dati

Il progetto è stato suddiviso in quattro fasi operative distinte:


- **Fase 1: Data Cleaning (Python):** Rimozione dei dati ridondanti, gestione dei valori nulli e normalizzazione delle stringhe (es. pulizia della nazionalità dei recensori).
- **Fase 2: Architettura Relazionale (SQL):** Progettazione di un database a 4 tabelle (Hotels, Reviewers, Reviews, Hotel_Stats) per ottimizzare le performance delle query e garantire l'integrità dei dati tramite vincoli di Foreign Key.
- **Fase 3: Sincronizzazione e Validazione:** Utilizzo di una pipeline di caricamento in Python che ha permesso di validare i dati al 100%, confrontando i risultati delle aggregazioni tra Pandas e MariaDB.
- **Fase 4: Analisi Avanzata e Feature Engineering:** Creazione di nuovi indicatori come il *Sentiment Base* (bilancio tra parole positive/negative) e il *Clustering delle Città*.

Nota sulla Data Integrity: La sincronizzazione tra Python e MariaDB è stata validata confrontando i risultati delle aggregazioni. Ad esempio, il calcolo del `Reviewer_Score` medio per città ha prodotto uno scarto dello 0.00% tra le librerie Pandas e le query SQL, garantendo l'assoluta affidabilità del database relazionale.

Risultati e Insight Strategici


3.1 Trend Temporali e Stagionalità

L'analisi cronologica rivela un mercato in salute con una crescita costante del volume di recensioni nel 2016. I picchi stagionali sono evidenti nei mesi di luglio, agosto e dicembre, indicando che il dataset riflette fedelmente i flussi turistici legati alle vacanze estive e invernali.



La visione annuale chiarisce che il 2016 rappresenta il cuore del dataset, mentre i cali del 2015 e 2017 sono puramente tecnici, legati ai limiti temporali di raccolta del dataset originale (luglio 2015 - agosto 2017).

3.2 Profilo dei Viaggiatori e Mercati Dominant:



Il mercato è fortemente polarizzato: i viaggiatori del Regno Unito rappresentano quasi la metà del dataset (~48%).


- UK vs Mondo: Nonostante l'alto volume, i recensori britannici mantengono una media voto di 8.48, leggermente superiore alla media internazionale (8.31).
- Il Mercato USA: Gli americani emergono come i recensori più "generosi" (media 8.78), indicando una diversa scala di valutazione culturale rispetto ai viaggiatori europei.

3.3 Performance Geografica e Qualità Percepita


Dalla mappatura delle città emerge un dato controintuitivo: Londra, pur essendo la città con più recensioni, non è la più amata.

- Top Quality: Le strutture di Vienna e Barcellona dominano la classifica della qualità percepita, posizionandosi nel cluster *"Top Destination"*.


- **Efficienza:** Il Ritz Paris e l'Hotel Casa Camper si confermano i leader assoluti per rating, dimostrando che l'eccellenza del servizio prescinde dal volume totale di traffico ricevuto.



Volume di Recensioni per Città



Distribuzione dello Score per le Top 3 Nazionalità




Interpretazione del Box Plot: La distribuzione degli USA è più compatta verso l'alto rispetto a quella UK, che presenta una coda di "outliers" (punti isolati in basso) molto più marcata, segnale di una maggiore severità o polarizzazione nei giudizi britannici.

3.4 Correlazione "Dissenso-Verbosità"


Uno degli insight più interessanti riguarda la lunghezza dei testi. Esiste una correlazione inversa tra soddisfazione e sforzo descrittivo:

- Gli utenti insoddisfatti (score 1-4) producono testi quasi due volte più lunghi rispetto ai clienti soddisfatti.
- La lunghezza media delle critiche (57 parole) suggerisce che il feedback negativo viene usato come strumento di "sfogo" e documentazione dettagliata del disservizio.


Distribuzione Lunghezza Recensioni per Fascia di Punteggio



Distribuzione Score vs Lunghezza (Effetto Nuvola)



Mappa di Correlazione tra le Variabili del Dataset



- **Sentiment vs Score (0.47):** Esiste una correlazione positiva moderata tra il *Sentiment Base* (calcolato sul testo) e il voto numerico, confermando la coerenza tra quanto scritto e quanto votato.
- **Negative Word Count (-0.38):** Il legame negativo più forte è tra il numero di parole negative e il rating finale: più il cliente è specifico nel criticare, più il voto crolla drasticamente.

Conclusioni per il Management e Future Roadmap

L'analisi integrata dei 515.000 dati di Booking.com ha permesso di delineare un quadro preciso dell'hotellerie di lusso europea tra il 2015 e il 2017. Oltre alla validazione tecnica della pipeline Python-SQL, i risultati offrono tre direttrici strategiche fondamentali:

1. Centralità del Mercato UK e Gestione del Rating

Il mercato britannico non è solo il più voluminoso (~48% del dataset), ma funge da vero e proprio "pivot" per la reputazione globale delle catene europee.

- **Insight:** Data l'elevata massa critica, una fluttuazione negativa nel sentiment dei viaggiatori UK ha un impatto matematico sproporzionato sul rating finale rispetto a qualsiasi altro mercato.
- **Azione:** È necessario implementare sistemi di monitoraggio in tempo reale per questo segmento, intervenendo prontamente sui disservizi segnalati per evitare l'effetto trascinamento del punteggio complessivo.

2. Il Paradosso di Londra e il Modello Vienna/Barcellona

Nonostante Londra detenga il primato per numero di recensioni, le città di Vienna e Barcellona si confermano i leader indiscussi per qualità percepita (rispettivamente 8.57 e 8.55).

- **Insight:** Questo divario suggerisce che l'eccellenza nel servizio (come dimostrato dai casi del *Ritz Paris* o dell'*Hotel Casa Camper*) è inversamente proporzionale alla saturazione del mercato.
- **Azione:** Utilizzare Vienna e Barcellona come *benchmark* operativi. Studiare i loro standard di accoglienza permette di identificare i driver di soddisfazione che mancano in mercati più maturi e potenzialmente più "freddi" come Londra o Milano.

3. Capitalizzazione del Feedback Negativo

L'analisi della correlazione "Dissenso-Verbosità" rappresenta l'opportunità di business più concreta emersa dal report.

- **Insight:** Il fatto che gli utenti insoddisfatti producano testi quasi due volte più lunghi (media 57 parole) indica che la recensione negativa non è solo un reclamo, ma una documentazione dettagliata di criticità oggettive.
- **Azione:** Trasformare il feedback negativo in una risorsa di *Business Intelligence*. Queste recensioni devono essere utilizzate dai General Manager come "audit gratuiti" per correggere falle operative specifiche (es. pulizia, tempi di attesa, manutenzione) che i clienti soddisfatti tendono a ignorare nei loro commenti brevi e generici.

4. Evoluzione Tecnica del Progetto

Dal punto di vista dell'architettura dati, il successo della pipeline di sincronizzazione tra Pandas e MariaDB apre la strada a future integrazioni:

1. **Sentiment Analysis Avanzata:** Implementazione di modelli di Natural Language Processing (NLP) più complessi per categorizzare automaticamente le recensioni lunghe in "temi" (es. Staff, Location, Price).
2. **Predittività:** Utilizzo del dataset per costruire modelli di Machine Learning in grado di prevedere il rating di una struttura basandosi puramente sul mix di nazionalità dei suoi futuri ospiti.